

MAE5834 - Estudo de Simulação Inferência Robusta - Gamma

Jaqueline Lamas da Silva (17646475), Olian Castanha Lima (13686261),
Oyindamola Olubusola Alalade (17647114)

Sumário

1 Introdução **2**

2 Modelo **2**

2.1 Estimador de Máxima Verossimilhança (EMV) 3

2.2 Estimador de Mínima Densidade Power Divergencia (MDPDE) 3

2.2.1 **Passo 4: Atualização via Mínimos Quadrados Iterativamente Reponderados (IRLS)** 3

2.2.2 (b) 4

3 Referências **6**

1 Introdução

Este trabalho prático tem como objetivo avaliar o desempenho do MDPDE em comparação ao EMV sob diferentes cenários de contaminação e valores da constante de afinação $\alpha \in [0, 1)$. Sorteamos no software R Core Team (2026) um número de 1 a 10 para definir o modelo a ser trabalhado. O modelo de número 3 foi sorteado, por isso, vamos trabalhar com o modelo de regressão Gamma. Nas seções a seguir vamos definir o modelo, apresentar as metodologias adotadas, descrever os cenários e discutir os resultados obtidos.

2 Modelo

Seja Y uma variável aleatória com distribuição gamma de média μ e coeficiente de variação $\phi^{-\frac{1}{2}}$. A função de densidade de probabilidade de Y é dada por:

$$f_Y(y, \mu, \phi) = exp\left\{\phi\left[\frac{-y}{\mu} - log(\mu)\right] - log(\Gamma(\phi)) + \phi log(\phi y) - log(y)\right\},$$

em que $y > 0$, $\phi > 0$, $\mu > 0$ e $\Gamma(\phi) = \int_0^\infty t^{\phi-1}e^{-t}dt$ é a função gama.

Seja $Y_1, \cdots, Y_n$ uma amostra aleatória com

$$Y_i|\mathbf{x_i} \overset{\text{ind}}{\sim} Gamma(\mu_i, \phi)$$
$$\eta_i = log(\mu_i), \eta_i = \mathbf{x_i}^\top \beta$$

Neste trabalho, vamos manter ϕ fixado, com isso, o vetor de parâmetros é $\beta = (\beta_0, \beta_1)^\top$. O vetor escore pode ser obtido derivando a log-verossimilhança em relação a β. Para a i-ésima observação ele é dado por:

$$u_\beta(y_i) = \phi\frac{(y_i - \mu_i)}{\mu_i}\mathbf{x_i},$$

em que $\mathbf{x_i}$ é a i-ésima linha da matriz $\mathbf{X}$. Para a amostra completa ele pode ser expresso como

$$U_\beta(y) = \phi\mathbf{X}^\top\mathbf{V}^{\frac{-1}{2}}(\mathbf{y} - \mathbf{X}\beta)$$

em que $\mathbf{V}^{-\frac{1}{2}} = \text{diag}\left\{\frac{1}{\mu_1}, \cdots, \frac{1}{\mu_n}\right\}$, pois a função de variânicia para a distribuição Gamma é $V(\mu) = \mu^2$.

2.1 Estimador de Máxima Verossimilhança (EMV)

As estimativas de máxima verossimilhança para β serão obtidas por meio do pacote do *gamlss* (Rigby & Stasinopoulos, 2005). Generalized additive models for location, scale and shape,(with discussion), Appl. Statist., 54, part 3, pp 507-554. .

2.2 Estimador de Mínima Densidade Power Divergencia (MDPDE)

O MDPDE minimiza a seguinte função perda:

$$H_n(\beta) = \frac{1}{n}\sum_{i=1}^{n}\left[\int_{\mathcal{X}} f_Y^{1+\alpha}(z;\mu_i,\phi)\,dz - \left(1+\frac{1}{\alpha}\right) f_Y^{\alpha}(Y_i;\mu_i,\phi)\right], \text{ para } \alpha \in [0,1). \tag{1}$$

Então a função score é:

$$\psi(y_i,\beta) = u_\beta(y_i) f_Y^{\alpha}(y_i;\mu_i,\phi) - \int_{\mathcal{X}} u_\beta(z) f_Y^{1+\alpha}(z;\mu,\phi)(z)dz$$

E as estimativas são obtidas resolvendo o sistema de equações de estimação:

$$\sum_{i=1}^{n}\psi_i(y_i,\beta) = \mathbf{0}$$

2.2.1 Passo 4: Atualização via Mínimos Quadrados Iterativamente Reponderados (IRLS)

A cada iteração m, o novo vetor de parâmetros $\beta^{(m+1)}$ é obtido resolvendo o problema de mínimos quadrados reponderados[cite: 3]:

$$\beta^{(m+1)} = \left(\mathbf{X}^\top \mathbf{W}_\alpha^{(m)} \mathbf{X}\right)^{-1} \mathbf{X}^\top \mathbf{W}_\alpha^{(m)} \mathbf{z}^{(m)}$$

em que:

1. **Matriz de Pesos Reponderada ($\mathbf{W}_\alpha^{(m)}$):**

$$\mathbf{W}_\alpha^{(m)} = \text{diag}\left\{w_1^{(m)}, w_2^{(m)}, \ldots, w_n^{(m)}\right\}$$

com $w_i^{(m)} = f_Y^{\alpha}(y_i;\mu_i^{(m)},\phi)$ ajustando o peso de cada observação conforme a sua densidade (robusteza à contaminação).

2. **Variável Dependente Modificada ($\mathbf{z}^{(m)}$):** Seguindo a estrutura de MLG $\mathbf{z} = \eta + \mathbf{W}^{-1}\mathbf{V}^{-\frac{1}{2}}(\mathbf{y}-\mu)$[cite: 3], adaptada com a correção do viés da integral do MDPDE (b_{soma}):

$$\mathbf{z}^{(m)} = \eta^{(m)} + \mathbf{e}^{(m)} - \frac{1}{\phi}\left(\mathbf{W}_{\alpha}^{(m)}\right)^{-1}\left(\mathbf{X}^{\top}\right)^{+} b_{\text{soma}}^{(m)}$$

onde $e_i^{(m)} = \frac{y_i - \mu_i^{(m)}}{\mu_i^{(m)}}$ são os resíduos proporcionais da distribuição Gamma com $V(\mu) = \mu^2$[cite: 2].

3. **Passo Equivalente no Código (Atualização Direta do Fisher Scoring):** A aplicação da equação do IRLS resulta na forma computacional direta implementada no algoritmo:

$$\beta^{(m+1)} = \beta^{(m)} + \left(\phi\mathbf{X}^{\top}\mathbf{W}_{\alpha}^{(m)}\mathbf{X}\right)^{-1}\Psi(y)^{(m)}$$

em que $\Psi(y)^{(m)} = \phi\mathbf{X}^{\top}\mathbf{W}_{\alpha}^{(m)}\mathbf{e}^{(m)} - b_{\text{soma}}^{(m)}$ representa o vetor escore reponderado total.

2.2.2 (b)

O modelo verdadeiro, ou seja, aquele que irá gerar as amostras é definido da seguinte maneira:

$$Y_i|\mathbf{x_i} \overset{\text{ind}}{\sim} Gamma(\mu_i, \phi)$$
$$\eta_i = log(\mu_i), \eta_i = \beta_0 + \beta_1 x_{i1}$$

em que

$$\beta = (0.3, 0.1)^{\top};\ \phi = 4;\ x_{i1} \sim U(1, 10);\ i = 1, \cdots, n.$$

####(c)

Mecanismos de Contaminação: Para cada amostra gerada, considere os seguintes cenários de contaminação com proporção $\epsilon in\{0$:

i) Cenário C0 (Sem contaminação): Dados puros gerados estritamente pelo modelo teórico.

```
[[1]]
[[1]]$rect
[[1]]$rect$w
[1] 0.7611472

[[1]]$rect$h
[1] 0.4299919

[[1]]$rect$left
[1] 2.078853
```

```
[[1]]$rect$top
[1] 0.900702


[[1]]$text
[[1]]$text$x
[1] 2.237886 2.237886 2.237886 2.237886 2.237886 2.237886

[[1]]$text$y
[1] 0.8392746 0.7778471 0.7164197 0.6549923 0.5935649 0.5321375



[[2]]
NULL

[[3]]
NULL

[[4]]
NULL

[[5]]
NULL

[[6]]
NULL

pdf
  2


[[1]]
[[1]]$rect
[[1]]$rect$w
[1] 0.7611472

[[1]]$rect$h
[1] 0.4299919

[[1]]$rect$left
[1] 2.078853
```

```
[[1]]$rect$top
[1] 0.900702


[[1]]$text
[[1]]$text$x
[1] 2.237886 2.237886 2.237886 2.237886 2.237886 2.237886

[[1]]$text$y
[1] 0.8392746 0.7778471 0.7164197 0.6549923 0.5935649 0.5321375



[[2]]
NULL

[[3]]
NULL

[[4]]
NULL

[[5]]
NULL

[[6]]
NULL


pdf
  2
```

3 Referências

Rigby R.A. and Stasinopoulos D.M. (2005). Generalized additive models for location, scale and shape,(with discussion), Appl. Statist., 54, part 3, pp 507-554.